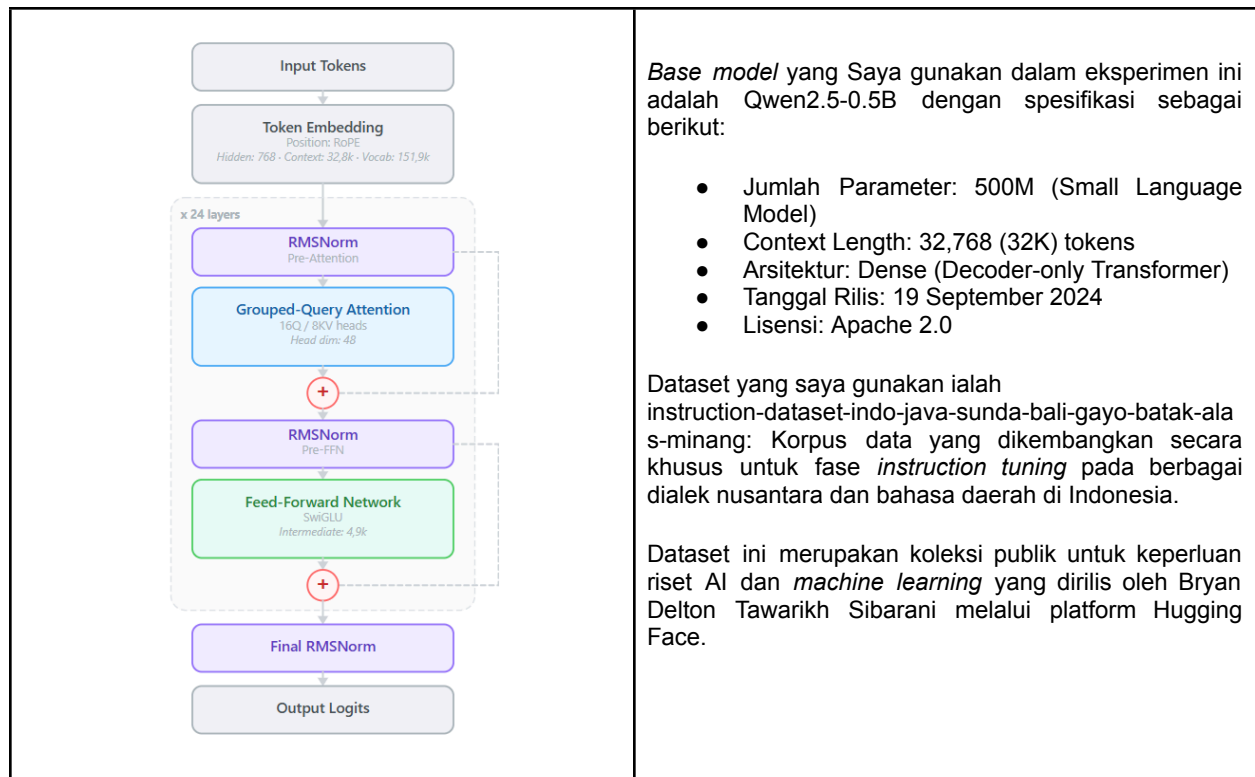


Laporan Supervised Fine-Tuning dengan LoRA - Tugas Akhir PBAL

Mohd Azhima - 25/562764/PPA/07080



Q1. Mengapa base model memiliki pengetahuan luas tetapi lemah dalam mengikuti instruksi? Jelaskan dari sudut pandang fungsi loss saat pre-training.

Jawab:

Jika dilihat dari sudut pandang fungsi loss pre-training pada model Qwen/Qwen2.5-0.5B yang saya peroleh dari [dokumentasi](#), model Qwen2.5-0.5B dilatih menggunakan metode *self-supervised learning* dengan membaca korpus data internet raksasa berskala triliunan token.

Tugas utama model selama fase ini dikendalikan oleh satu objektif matematis tunggal: Next-Token Prediction (Prediksi Token Berikutnya). Fungsi loss yang digunakan secara eksklusif untuk mengevaluasi kesalahan model adalah Cross-Entropy Loss. Dalam tahapan ini, fungsi loss *pre-training* tidak memedulikan aspek kegunaan atau relevansi jawaban model terhadap instruksi tertentu. Fokus utamanya hanya terletak pada apakah kelanjutan teks tersebut sejalan dengan pola-pola bahasa yang ditemukan pada korpus data internet. Hal itulah yang membuat model lebih cenderung untuk melengkapi atau memprediksi teks berikutnya alih-alih mematuhi instruksi.

Oleh karena itu dibutuhkan layer tambahan yang dapat memodifikasi loss menggunakan Supervised Fine-Tuning (SFT) untuk menerapkan aturan seperti instruksi dan respon.

Q2. Berapa persen parameter yang Anda latih dengan LoRA dibanding total parameter model? Apa dampaknya terhadap efisiensi?

Jawab:

Berdasarkan hasil eksperimen yang telah dilakukan, metode *Low-Rank Adaptation* (LoRA) yang diterapkan melibatkan pelatihan sebanyak 8.798.208 parameter dari total 502.830.976 parameter model. Angka ini menunjukkan rasio parameter terlatih yang sangat efisien, yaitu hanya sebesar 1,75%. Konfigurasi tersebut menggunakan nilai rank $r=16$ dan $lora_alpha=32$. Sebagai perbandingan, pengujian sebelumnya dengan pengaturan $r=8$ dan $lora_alpha=16$ menghasilkan jumlah parameter terlatih yang jauh lebih rendah, yakni di bawah angka 1%.

Dampaknya terhadap efisiensi sangat signifikan, karena pembaruan bobot hanya dilakukan pada sebagian kecil parameter, yang secara drastis mengurangi beban komputasi dan kebutuhan memori selama proses pelatihan tanpa mengorbankan performa model secara keseluruhan.

```
=====
RINGKASAN INTEGRASI PARAMETER LoRA
=====
Parameter dilatih (Trainable) : 8,798,208 (1.75%)
Parameter beku (Frozen)       : 494,032,768 (98.25%)
Parameter total keseluruhan   : 502,830,976
=====
```

Q3. Tampilkan 3 contoh respons model sebelum dan sesudah fine-tuning. Analisis Perbedaannya.

Jawab:

Prompt 1: *Jelaskan makna filosofi Bugis 'Siri Na Pacce' dan relevansinya dalam kehidupan modern.*

Base Model (Sebelum Latihan)	Fine-Tuned Model (Setelah Latihan)
Filosofi Bugis 'Siri Na Pacce' merupakan konsep yang membangun dari istilah-istilah bahasa Inggris seperti "Paci" ... Hubungan yang tidak bisa dikatakan sebagai 'kita' terhadap 'bukan kita' ... [Terputus]	Filosofia 'Siri Na Pacce' menerangkan bahwa berada di sektor bisnis adalah pekerjaan yang paling menarik, karena mereka dapat mengembangkan produk atau layanan yang membawa keadilan... [Selesai]

Analisis:

- Base Model: Mengalami *text-completion syndrome*. Model tidak menjawab instruksi melainkan berasumsi sedang menulis artikel bebas, berhalusinasi pada pencarian akar kata ("Paci"), dan kalimatnya terputus karena keterbatasan token.
- Fine-Tuned Model: Secara struktur lebih rapi karena mampu menyelesaikan paragraf tanpa terputus. Namun, isinya salah total (Fluency without Fidelity). Model mengubah filosofi moral/harga diri Bugis menjadi teori manajemen bisnis dan CSR. Ini mengindikasikan dataset *fine-tuning* Anda mengalami bias berat pada topik korporat/bisnis.

Prompt 2: *Terjemahkan ke bahasa Sunda: 'Saya sangat senang bertemu dengan Anda hari ini.'*

Base Model (Sebelum Latihan)	Fine-Tuned Model (Setelah Latihan)
"Istilah yang diambil dari sebuah kata dalam Bahasa Indonesia adalah... Halo, Anda mungkin mengalami kesulitan... 1. Kebijakan Bisnis..."	"Bahasa Indonesia : 'Selamat datang...' Inggris : 'Sejahtera...' Indoneunian : 'Tidak ada kata...' Kalimantan Timur : 'Hanya beberapa kali...' Meksiko : 'Aku ingin...'"

Analisis:

- Base Model: Mengabaikan perintah terjemahan dan malah mengoceh tentang definisi kalimat tersebut dalam konteks "Kebijakan Bisnis".
- Fine-Tuned Model: Mengalami Disorientasi Bahasa (Language Collapse). Model gagal total menerjemahkan ke bahasa Sunda, dan justru membuat daftar acak multi-bahasa yang tidak sinkron (mengada-ada bahasa "Indoneunian", menyamakan Meksiko dan Kalimantan sebagai bahasa, serta salah menerjemahkan teks aslinya).

Prompt 3: *Bagaimana cara membuat opor ayam? Sebutkan bahan dan langkahnya.*

Base Model (Sebelum Latihan)	Fine-Tuned Model (Setelah Latihan)
"Ternyata, ada banyak jenis bahan... Mengolah Ayam Daging Berkurung... Teman saya pernah bekerja sama dengan masing-masing pihak dalam menyediakan [Terputus]"	"Anda dapat menghasilkan opor ayam dengan mengolah kue asli atau menggunakan beberapa bahan yang biasa, seperti tepung, tepung, tepung, tepung, tepung, tepung, tepung, tepung..."

Analisis:

- Base Model: Terjebak dalam basa-basi penulisan artikel (pengantar yang berputar-putar tentang "Ayam Berkurung") tanpa pernah masuk ke inti resep.
- Fine-Tuned Model: Mengalami Degenerasi Repetitif (Repetitive Loops). Model terjebak dalam pusaran probabilitas kata yang sama ("*tepung*") hingga batas token habis. Selain itu, logika resepnya rusak karena menyebut opor ayam dibuat dari "kue asli" dan "tepung".

Q4. Apa risiko overfitting pada dataset kecil? Bagaimana Anda mendeteksi dan Mencegahnya?

Jawab:

Ada dua isu utama overfitting yang umum saya temukan ketika berexperimen dengan dataset kecil yaitu:

- Kegagalan Generalisasi (Model Menjadi Kaku): Hal ini menyebabkan model kehilangan kapabilitas untuk memprediksi data baru yang berada di luar cakupan data latih.
- Terlalu Sensitif terhadap *Noise* (*Outliers*): Dalam dataset berskala besar, anomali atau data dengan label yang keliru tidak akan berdampak signifikan. Namun, pada dataset kecil, data yang cacat memiliki bobot pengaruh yang sangat dominan, sehingga model memaksakan diri untuk memodifikasi logikanya demi mengakomodasi kesalahan tersebut.

Cara mendeteksi dan mencegahnya sebagai berikut:

1. Kurva Loss Naik -> Early Stopping

- **Deteksi:** *Training loss* terus turun, tetapi *validation loss* tiba-tiba melengkung naik.
- **Cegah:** Hentikan proses *training* secara otomatis tepat sebelum kurva validasi mulai naik (*Early Stopping*).

2. Akurasi Jomplang -> Dropout & Regularisasi

- **Deteksi:** Akurasi data latih nyaris 100%, tetapi akurasi validasi sangat rendah (model hanya menghafal).
- **Cegah:** Persulit memori model dengan **Dropout** (mematikan sebagian neuron secara acak), **Regularisasi L1/L2** (memberi penalti pada bobot berlebih), atau sederhanakan ukuran model.

3. Prediksi Labil (Varian Tinggi) -> Augmentasi & K-Fold

- **Deteksi:** Hasil prediksi berubah drastis hanya karena sedikit perubahan susunan data latih.
- **Cegah:** Perbanyak variasi data secara buatan (**Augmentasi**) dan uji model dengan memecah data menjadi beberapa lipatan bergilir (**K-Fold Cross-Validation**).

Q5. (Bonus) Jika Anda membuat dataset bahasa daerah sendiri: apa tantangan utama dalam membuat data berkualitas tinggi? Apa yang Anda pelajari?

Jawab:

- Dalam menyusun dataset sintetis, Saya memanfaatkan bantuan AI guna mempermudah penulisan format JSON serta penggalian ide dari literatur digital. Namun, hasil tersebut tidak dapat dipercaya sepenuhnya (100%). Tetap diperlukan filter manusia guna memverifikasi logika, keakuratan fakta budaya maupun sejarah, hingga tata bahasanya. Kendala lainnya adalah keterbatasan referensi yang sering kali menyebabkan kebuntuan ide, sehingga Saya cenderung terjebak dalam bias atau terlalu mendominasi pada satu topik spesifik tertentu.
- Ketika Kehadiran kosakata bahasa Sunda (*naon, henteu*), Jawa (*kanthi, kahanané*), hingga Bali (*nenten, inggih*) pada luaran *base model* mengindikasikan bahwa dataset yang digunakan—baik pada fase *pre-training* maupun *fine-tuning*—merupakan hasil *scraping* internet yang tercampur aduk secara masif. Model gagal membedakan batas-batas morfologis antara Bahasa Kerinci dengan dialek nusantara lainnya, sehingga pemicu bahasa daerah justru menghasilkan respon "gado-gado" yang tidak koheren.
- Bahasa Kerinci tergolong sebagai *low-resource language* akibat kelangkaan literatur digital. *Base model* yang digunakan besar kemungkinan tidak memiliki pondasi pengetahuan terhadap leksikal Kerinci (seperti *camano, agih, untuak, gihoih*). Imbasnya, ketika dipaksa memproses dataset spesifik berskala kecil, model mengalami degradasi memori (*Catastrophic Forgetting*). Hal ini memicu model untuk mengambil memori dari bahasa daerah lain yang memiliki bobot statistik lebih dominan, seperti bahasa Jawa atau Sunda.